

# Cadenas de markov vistas desde la inferencia bayesiana

Carlos Alejandro Luna Zavala

2026

## 1 Inferencia Bayesiana para Cadenas de Markov

En esta sección se desarrolla el marco analítico para la estimación de las probabilidades de transición de una Cadena de Markov en tiempo discreto con un espacio de estados  $\xi = \{0, 1\}$ . Sea  $X_{\text{obs}}$  una trayectoria observada de longitud  $n$ .

### 1.1 Función de Verosimilitud

Definimos los parámetros objetivo del modelo como  $\theta$  (probabilidad inicial),  $\alpha$  (probabilidad de transición del estado 0 al 1) y  $\beta$  (probabilidad de transición del estado 1 al 0). La verosimilitud conjunta del proceso, denotada como  $L(\theta, \alpha, \beta | X_{\text{obs}})$ , se construye a partir de los conteos empíricos de las transiciones  $n_{ij}$ , resultando en:

$$L(\theta, \alpha, \beta | X_{\text{obs}}) = \theta^{x_0} (1 - \theta)^{1-x_0} (1 - \alpha)^{n_{00}} \alpha^{n_{01}} \beta^{n_{10}} (1 - \beta)^{n_{11}} \quad (1)$$

### 1.2 Distribuciones a Priori

Debido a que los parámetros representan probabilidades y su dominio está restringido al intervalo  $[0, 1]$ , se opta por utilizar distribuciones de la familia conjugada Beta. Para reflejar un estado de ignorancia total y garantizar la invariancia ante reparametrizaciones, se asume la distribución no informativa de Jeffreys,  $\text{Beta}(0.5, 0.5)$ , para todos los parámetros de manera independiente:

$$P(\theta, \alpha, \beta) \propto [\theta^{-0.5} (1 - \theta)^{-0.5}] [\alpha^{-0.5} (1 - \alpha)^{-0.5}] [\beta^{-0.5} (1 - \beta)^{-0.5}] \quad (2)$$

### 1.3 Distribuciones a Posteriori

Aplicando el Teorema de Bayes, la distribución conjunta a posteriori es proporcional al producto de la verosimilitud empírica (1) y la distribución a priori (2). Al agrupar las bases idénticas, se demuestra analíticamente que la independencia paramétrica se mantiene condicionada a los datos:

$$P(\theta, \alpha, \beta | X_{\text{obs}}) \propto L(\theta, \alpha, \beta | X_{\text{obs}}) \times P(\theta, \alpha, \beta) \quad (3)$$

Desarrollando esta expresión, obtenemos las siguientes distribuciones marginales a posteriori exactas, las cuales servirán de base para la construcción de los intervalos de credibilidad (Highest Posterior Density):

$$\theta | X_{\text{obs}} \sim \text{Beta}(x_0 + 0.5, 1 - x_0 + 0.5) \quad (4)$$

$$\alpha | X_{\text{obs}} \sim \text{Beta}(n_{01} + 0.5, n_{00} + 0.5) \quad (5)$$

$$\beta | X_{\text{obs}} \sim \text{Beta}(n_{10} + 0.5, n_{11} + 0.5) \quad (6)$$

#### 1.4 Generalización para $M$ Trayectorias Independientes

En la práctica actuarial y el modelado estadístico, es común observar múltiples trayectorias independientes del mismo proceso estocástico para reducir la incertidumbre. Supongamos que ahora nuestra muestra completa observada, denotada globalmente como  $X_{\text{obs}}$ , se compone de  $M$  trayectorias independientes  $X^{(m)}$  para  $m = 1, 2, \dots, M$ .

Para simplificar la notación de la verosimilitud conjunta, definimos los conteos agregados globales para los estados iniciales y las transiciones como:

$$y_0 = \sum_{m=1}^M x_0^{(m)} \quad \text{y} \quad N_{ij} = \sum_{m=1}^M n_{ij}^{(m)} \quad (7)$$

donde  $y_0$  representa el número total de trayectorias que iniciaron en el estado 1, y  $N_{ij}$  es el total de transiciones del estado  $i$  al estado  $j$  sumando toda la muestra  $X_{\text{obs}}$ . Dado que las trayectorias son independientes, la función de verosimilitud conjunta global se obtiene multiplicando las verosimilitudes individuales:

$$L(\theta, \alpha, \beta | X_{\text{obs}}) = \theta^{y_0} (1 - \theta)^{M - y_0} (1 - \alpha)^{N_{00}} \alpha^{N_{01}} \beta^{N_{10}} (1 - \beta)^{N_{11}} \quad (8)$$

Al multiplicar esta nueva verosimilitud global por las distribuciones a priori de Jeffreys previamente definidas, obtenemos las distribuciones a posteriori actualizadas para el caso de  $M$  trayectorias:

$$\theta | X_{\text{obs}} \sim \text{Beta}(y_0 + 0.5, M - y_0 + 0.5) \quad (9)$$

$$\alpha | X_{\text{obs}} \sim \text{Beta}(N_{01} + 0.5, N_{00} + 0.5) \quad (10)$$

$$\beta | X_{\text{obs}} \sim \text{Beta}(N_{10} + 0.5, N_{11} + 0.5) \quad (11)$$

Este enfoque generalizado es matemáticamente crítico, ya que al incorporar el volumen de datos de las  $M$  trayectorias contenidas en  $X_{\text{obs}}$ , la varianza de las distribuciones a posteriori colapsa. Esto permite obtener intervalos de credibilidad estrechos y estimaciones precisas, resolviendo en particular el problema de alta incertidumbre sobre la distribución inicial  $\theta$  que ocurre al observar una única trayectoria.

## 1.5 Código Fuente en Python

A continuación se presenta el código computacional completo utilizado para la simulación de las trayectorias de la Cadena de Markov y la validación frecuentista de los intervalos de credibilidad bayesianos.

```

1 import numpy as np # Importa numpy para operaciones vectorizadas
2 import matplotlib.pyplot as plt # Importa pyplot para graficar
3 from scipy.stats import beta # Importa la distribucion beta
4 import matplotlib.lines as mlines # Importa utilidades para crear
   la leyenda
5
6 def simulador_maestro_panel():
7     # 1. Definicion de parametros reales
8     true_theta = 0.60
9     true_alpha = 0.30
10    true_beta = 0.70
11
12    # 2. Configuracion global
13    num_experimentos = 10000
14    M = 50
15    nivel_alpha = 0.05
16    a_pri, b_pri = 0.5, 0.5
17
18    # Contadores para consola
19    exitos_t_total, exitos_a_total, exitos_b_total = 0, 0, 0
20
21    # Listas para la grafica (solo 100 experimentos)
22    num_grafica = 100
23
24    # Diccionarios para guardar los datos de los 3 parametros de
   forma ordenada
25    datos_grafica = {
26        'theta': {'medias': [], 'inf': [], 'sup': [], 'exito': []},
27        'alpha': {'medias': [], 'inf': [], 'sup': [], 'exito': []},
28        'beta': {'medias': [], 'inf': [], 'sup': [], 'exito': []}
29    }
30
31    print(f"Iniciando {num_experimentos} simulaciones...")
32    print(f"Cada simulacion genera {M} trayectorias con longitudes
   distintas.")
33    print("-" * 60)
34
35    # 3. Bucle de simulacion
36    for i in range(num_experimentos):
37        longitudes = np.random.randint(10, 61, size=M)
38        max_len = longitudes.max()
39

```

```

40     estados = np.zeros((M, max_len + 1), dtype=int)
41     estados[:, 0] = np.random.binomial(1, true_theta, size=M)
42
43     for t in range(max_len):
44         estado_actual = estados[:, t]
45         probs = np.where(estado_actual == 0, true_alpha, 1 -
true_beta)
46         estados[:, t+1] = np.random.binomial(1, probs)
47
48         mascara = np.arange(max_len) < longitudes[:, None]
49         trans_origen = estados[:, :-1][mascara]
50         trans_destino = estados[:, 1:][mascara]
51
52         y0 = np.sum(estados[:, 0])
53         N00 = np.sum((trans_origen == 0) & (trans_destino == 0))
54         N01 = np.sum((trans_origen == 0) & (trans_destino == 1))
55         N10 = np.sum((trans_origen == 1) & (trans_destino == 0))
56         N11 = np.sum((trans_origen == 1) & (trans_destino == 1))
57
58         a_post_theta, b_post_theta = y0 + a_pri, (M - y0) + b_pri
59         a_post_alpha, b_post_alpha = N01 + a_pri, N00 + b_pri
60         a_post_beta, b_post_beta = N10 + a_pri, N11 + b_pri
61
62         int_t = beta.ppf([nivel_alpha/2, 1 - nivel_alpha/2],
a_post_theta, b_post_theta)
63         int_a = beta.ppf([nivel_alpha/2, 1 - nivel_alpha/2],
a_post_alpha, b_post_alpha)
64         int_b = beta.ppf([nivel_alpha/2, 1 - nivel_alpha/2],
a_post_beta, b_post_beta)
65
66         exito_t = int_t[0] <= true_theta <= int_t[1]
67         exito_a = int_a[0] <= true_alpha <= int_a[1]
68         exito_b = int_b[0] <= true_beta <= int_b[1]
69
70         if exito_t: exitos_t_total += 1
71         if exito_a: exitos_a_total += 1
72         if exito_b: exitos_b_total += 1
73
74         # Guardar datos para los 3 parametros si estamos en las
primeras 100 iteraciones
75         if i < num_grafica:
76             datos_grafica['theta']['medias'].append(a_post_theta /
(a_post_theta + b_post_theta))
77             datos_grafica['theta']['inf'].append(int_t[0])
78             datos_grafica['theta']['sup'].append(int_t[1])
79             datos_grafica['theta']['exito'].append(exito_t)
80
81             datos_grafica['alpha']['medias'].append(a_post_alpha /
(a_post_alpha + b_post_alpha))
82             datos_grafica['alpha']['inf'].append(int_a[0])
83             datos_grafica['alpha']['sup'].append(int_a[1])
84             datos_grafica['alpha']['exito'].append(exito_a)
85
86             datos_grafica['beta']['medias'].append(a_post_beta / (
a_post_beta + b_post_beta))
87             datos_grafica['beta']['inf'].append(int_b[0])
88             datos_grafica['beta']['sup'].append(int_b[1])

```

```

89         datos_grafica['beta']['exitos'].append(exito_b)
90
91     # 4. Impresion en consola
92     print("RESULTADOS DE COBERTURA FRECUENTISTA (Intervalos
93     Aleatorios del 95%):")
94     print(f"El valor oculto de Theta ({true_theta}) cayo en el
95     intervalo el { exitos_t_total / num_experimentos * 100:.2f}% de
96     las veces.")
97     print(f"El valor oculto de Alpha ({true_alpha}) cayo en el
98     intervalo el { exitos_a_total / num_experimentos * 100:.2f}% de
99     las veces.")
100     print(f"El valor oculto de Beta ({true_beta}) cayo en el
101     intervalo el { exitos_b_total / num_experimentos * 100:.2f}% de
102     las veces.")
103
104     # 5. Construccion del panel de 3 graficas
105     fig, axs = plt.subplots(1, 3, figsize=(18, 6)) # 1 fila, 3
106     columnas
107     fig.suptitle('Validacion Empirica: Cobertura de Intervalos de
108     Credibilidad del 95%', fontsize=16)
109
110     parametros = [
111         ('theta', true_theta, 'Probabilidad Inicial (Theta)'),
112         ('alpha', true_alpha, 'Transicion 0 -> 1 (Alpha)'),
113         ('beta', true_beta, 'Transicion 1 -> 0 (Beta)')
114     ]
115
116     # Bucle para dibujar cada una de las 3 subgraficas
117     for idx, (llave, valor_real, titulo) in enumerate(parametros):
118         ax = axs[idx]
119         for i in range(num_grafica):
120             color = 'blue' if datos_grafica[llave]['exitos'][i] else
121             'red'
122             ax.plot([i, i], [datos_grafica[llave]['inf'][i],
123             datos_grafica[llave]['sup'][i]], color=color, alpha=0.7)
124             ax.plot(i, datos_grafica[llave]['medias'][i], marker='o',
125             markersize=3, color=color)
126
127             ax.axhline(y=valor_real, color='black', linestyle='--',
128             linewidth=2)
129             ax.set_title(titulo)
130             ax.set_xlabel('Simulacion')
131             ax.set_ylabel('Valor Estimado')
132             ax.grid(True, alpha=0.2)
133
134             # Fijar los limites del eje Y para que se vea claro el
135             intervalo entre 0 y 1
136             if llave == 'theta': ax.set_ylim(0.2, 1.0)
137             elif llave == 'alpha': ax.set_ylim(0.0, 0.6)
138             elif llave == 'beta': ax.set_ylim(0.4, 1.0)
139
140     # Leyenda general para todo el panel
141     leyenda_azul = mlines.Line2D([], [], color='blue', marker='o',
142     markersize=5, label='Intervalo Exitoso')
143     leyenda_roja = mlines.Line2D([], [], color='red', marker='o',
144     markersize=5, label='Intervalo Fallido')

```

```

129 leyenda_negra = mlines.Line2D([], [], color='black', linestyle=
    '--', label='Valor Real')
130 fig.legend(handles=[leyenda_negra, leyenda_azul, leyenda_roja],
    loc='upper right', bbox_to_anchor=(1, 1))
131
132 plt.tight_layout(rect=[0, 0, 1, 0.95]) # Ajusta espacios para
    no superponer el titulo principal
133 plt.savefig('cobertura_intervalos.pdf', format='pdf',
    bbox_inches='tight')
134 plt.show()
135
136 simulador_maestro_panel()

```

Listing 1: Código completo del simulador bayesiano.

Esto nos genera una gráfica que se presentará a continuación y explicaremos.




Figure 1: Validación empírica de la cobertura frecuentista para los intervalos de credibilidad bayesianos del 95% (basados en la a priori de Jeffreys). Se presentan los primeros 100 experimentos simulados para los parámetros  $\theta$ ,  $\alpha$  y  $\beta$ . Las líneas verticales azules representan intervalos que capturaron exitosamente el valor real, mientras que las rojas representan fallos (aproximadamente el 5% esperado).

En general, obtenemos los siguientes resultados de la cobertura frecuentista:

- El valor oculto de  $\theta$  (0.6) cayó en el intervalo el 94.26% de las veces.
- El valor oculto de  $\alpha$  (0.3) cayó en el intervalo el 94.99% de las veces.
- El valor oculto de  $\beta$  (0.7) cayó en el intervalo el 94.94% de las veces.

## 2 Inferencia en tres estados

Ahora observaremos cómo se comporta para 3 estados. Supongamos una Cadena de Markov en tiempo discreto con un espacio de estados  $\xi = \{0, 1, 2\}$ . Para ilus-

trar la teoría matemática subyacente, consideraremos la estructura topológica más habitual en el modelado actuarial (como en modelos de supervivencia o ruina): los estados 0 y 1 son transitorios, mientras que el estado 2 es un estado absorbente.

## 2.1 Matriz de Transición y Parámetros Libres

Dado que el estado 2 es absorbente, su fila en la matriz de transición es determinista ( $p_{22} = 1$ ). Por lo tanto, la inferencia bayesiana se restringe a las filas de los estados transitorios, ya que son las únicas que contienen incertidumbre paramétrica. La matriz de transición estocástica  $P$  se define como:

$$P = \begin{pmatrix} p_{00} & p_{01} & p_{02} \\ p_{10} & p_{11} & p_{12} \\ 0 & 0 & 1 \end{pmatrix} \quad (12)$$

## 2.2 Función de Verosimilitud Multinomial

Al incorporar un tercer estado, los conteos empíricos de las transiciones salientes de un estado  $i$  (para  $i \in \{0, 1\}$ ) ya no siguen una distribución Binomial, sino una distribución Multinomial. La verosimilitud de la fila  $i$ , condicionada a la restricción geométrica de que  $\sum_{j=0}^2 p_{ij} = 1$ , es proporcional a:

$$L(p_{i0}, p_{i1}, p_{i2} | X_{\text{obs}}) \propto p_{i0}^{N_{i0}} p_{i1}^{N_{i1}} p_{i2}^{N_{i2}} \quad (13)$$

donde  $N_{ij}$  representa el conteo global de transiciones observadas del estado  $i$  al estado  $j$  a lo largo de toda la muestra empírica.

## 2.3 Distribución a Priori de Dirichlet

La familia de distribuciones conjugadas naturales para la función Multinomial es la distribución de Dirichlet, la cual representa una generalización multivariada de la distribución Beta sobre un simplex estocástico. Asignamos una distribución a priori independiente para cada fila transitoria. Adoptando el principio de Jeffreys para procesos multinomiales, los hiperparámetros se establecen en 0.5 para garantizar la invariancia analítica:

$$p_{i\cdot} \sim \text{Dirichlet}(0.5, 0.5, 0.5) \quad (14)$$

## 2.4 Distribución a Posteriori y Propiedades Marginales

Gracias a la conjugación matemática, la distribución conjunta a posteriori para el vector de probabilidades de la fila  $i$  se obtiene sumando directamente los conteos empíricos a los hiperparámetros iniciales:

$$p_{i\cdot} | X_{\text{obs}} \sim \text{Dirichlet}(N_{i0} + 0.5, N_{i1} + 0.5, N_{i2} + 0.5) \quad (15)$$

Aunque la actualización conjunta ocurre en múltiples dimensiones simultáneamente, la inferencia sobre una transición individual se simplifica notablemente. Una propiedad fundamental de la distribución de Dirichlet es que sus distribuciones marginales pertenecen a la familia Beta. Matemáticamente, si nos interesa exclusivamente la probabilidad de transición  $p_{ij}$ , su distribución marginal a posteriori agrupa el conteo del evento de interés contra la suma de los conteos de los otros destinos posibles:

$$p_{ij}|X_{\text{obs}} \sim \text{Beta} \left( N_{ij} + 0.5, \sum_{k \neq j} (N_{ik} + 0.5) \right) \quad (16)$$

Esto queda pendiente a revisión.