

1 Inferencia Bayesiana para Cadenas de Markov de Dos Estados

En esta sección se desarrolla el marco analítico exhaustivo para la estimación de las probabilidades de transición de una Cadena de Markov en tiempo discreto con un espacio de estados $\xi = \{0, 1\}$. El objetivo es transitar desde la observación empírica de una trayectoria hasta la construcción de intervalos de credibilidad rigurosos.

1.1 Matriz de Probabilidades de Transición

Definimos los parámetros objetivo del modelo de la siguiente manera: θ representa la probabilidad inicial de que el proceso comience en el estado 1; α es la probabilidad de transición del estado 0 al 1; y β es la probabilidad de transición del estado 1 al 0.

Bajo la propiedad de Markov, el comportamiento del sistema queda completamente caracterizado por su matriz de transición estocástica P . Dado que las probabilidades de salida de cada estado deben sumar la unidad, la matriz se define en función de los parámetros libres α y β :

$$P = \begin{pmatrix} p_{00} & p_{01} \\ p_{10} & p_{11} \end{pmatrix} = \begin{pmatrix} 1 - \alpha & \alpha \\ \beta & 1 - \beta \end{pmatrix} \quad (1)$$

Es imperativo notar que α y β operan sobre filas distintas de la matriz, por lo que son parámetros estadísticamente independientes entre sí.

1.2 Construcción de la Función de Verosimilitud

Sea $X_{\text{obs}} = (x_0, x_1, \dots, x_n)$ una trayectoria observada. La probabilidad conjunta de observar esta secuencia exacta se obtiene multiplicando la probabilidad del estado inicial por el producto de las probabilidades de cada transición subsecuente.

Agrupando las transiciones idénticas mediante conteos empíricos n_{ij} (donde n_{ij} es el número de veces que el sistema pasó del estado i al estado j), la función de verosimilitud toma la forma del producto de distribuciones Binomiales independientes:

$$L(\theta, \alpha, \beta | X_{\text{obs}}) \propto \theta^{x_0} (1 - \theta)^{1 - x_0} \times \alpha^{n_{01}} (1 - \alpha)^{n_{00}} \times \beta^{n_{10}} (1 - \beta)^{n_{11}} \quad (2)$$

1.3 Elección de la A Priori y Conjugación Matemática

En el paradigma bayesiano, los parámetros se tratan como variables aleatorias. Dado que θ , α y β representan probabilidades continuas restringidas al intervalo $[0, 1]$, la familia de distribuciones naturales para modelarlas es la distribución Beta.

La elección de la distribución Beta no es arbitraria; responde al principio de **conjugación matemática**. La distribución Beta es la a priori conjugada de la verosimilitud Binomial. Esto garantiza que la distribución a posteriori resultante pertenecerá a la misma familia analítica que la a priori.

Para reflejar un estado de ignorancia inicial y asegurar la invariancia ante reparametrizaciones, se asume la distribución no informativa de Jeffreys, Beta(0.5, 0.5), para todos los parámetros:

$$P(\theta, \alpha, \beta) \propto [\theta^{-0.5}(1-\theta)^{-0.5}] [\alpha^{-0.5}(1-\alpha)^{-0.5}] [\beta^{-0.5}(1-\beta)^{-0.5}] \quad (3)$$

1.4 Derivación de la Distribución a Posteriori

Aplicando el Teorema de Bayes, la distribución conjunta a posteriori es proporcional al producto de la verosimilitud (2) y la a priori (3). Al multiplicar ambas expresiones, las bases idénticas se agrupan sumando algebraicamente sus exponentes. Por ejemplo, para el parámetro α :

$$\alpha^{n_{01}}(1-\alpha)^{n_{00}} \times \alpha^{-0.5}(1-\alpha)^{-0.5} = \alpha^{n_{01}-0.5}(1-\alpha)^{n_{00}-0.5} \quad (4)$$

Dado que el resultado analítico tiene exactamente la estructura del núcleo de una distribución Beta (es decir, $x^{a-1}(1-x)^{b-1}$), concluimos formalmente que las distribuciones marginales a posteriori exactas son:

$$\theta|X_{\text{obs}} \sim \text{Beta}(x_0 + 0.5, 1 - x_0 + 0.5) \quad (5)$$

$$\alpha|X_{\text{obs}} \sim \text{Beta}(n_{01} + 0.5, n_{00} + 0.5) \quad (6)$$

$$\beta|X_{\text{obs}} \sim \text{Beta}(n_{10} + 0.5, n_{11} + 0.5) \quad (7)$$

1.5 Generalización para M Trayectorias

En la vida diaria es común observar múltiples individuos. Supongamos que nuestra muestra completa, denotada globalmente como X_{obs} , se compone de M trayectorias independientes.

Definimos los conteos agregados globales como $y_0 = \sum_{m=1}^M x_0^{(m)}$ y $N_{ij} = \sum_{m=1}^M n_{ij}^{(m)}$. Sustituyendo estos conteos globales en las ecuaciones anteriores, obtenemos las distribuciones a posteriori finales que colapsan su varianza gracias a la ley de los grandes números:

$$\theta|X_{\text{obs}} \sim \text{Beta}(y_0 + 0.5, M - y_0 + 0.5) \quad (8)$$

$$\alpha|X_{\text{obs}} \sim \text{Beta}(N_{01} + 0.5, N_{00} + 0.5) \quad (9)$$

$$\beta|X_{\text{obs}} \sim \text{Beta}(N_{10} + 0.5, N_{11} + 0.5) \quad (10)$$

1.6 Estimación Puntual: MAP vs. MLE

En el marco de la Teoría Bayesiana de Decisiones, la selección de un estimador puntual requiere la definición de una función de pérdida. En este trabajo se adopta la función de pérdida "Todo o Nada", cuyo estimador óptimo congruente es el que maximiza la densidad absoluta de probabilidad a posteriori, conocido como el estimador MAP (Maximum A Posteriori). Para una distribución marginal Beta(a, b), este estimador corresponde a la moda analítica:

$$\hat{p}_{\text{MAP}} = \frac{a - 1}{a + b - 2} \quad (11)$$

Es crucial justificar teóricamente el uso del estimador MAP frente al tradicional estimador de Máxima Verosimilitud (MLE). El paradigma frecuentista del MLE depende exclusivamente de la evidencia empírica reciente, maximizando únicamente la función de verosimilitud e ignorando cualquier información estructural previa. Adoptar el estimador MLE en este contexto fracturaría la congruencia teórica del modelo, ya que equivaldría a descartar la distribución a priori de Jeffreys (3), la cual fue rigurosamente definida para garantizar la invariancia analítica del espacio paramétrico.

Además, desde una perspectiva práctica en la simulación estocástica, el estimador MAP actúa como un regularizador natural ante muestras finitas o censuradas. Si en una trayectoria observada no ocurriera ninguna transición hacia un estado específico (por ejemplo, $N_{01} = 0$), el estimador MLE colapsaría asignando una probabilidad de transición de cero absoluto, incurriendo en un grave problema de sobreajuste. En contraste, el estimador MAP, al estar fundamentado en la distribución a priori, previene este colapso probabilístico permitiendo predicciones robustas incluso en escenarios de alta escasez empírica.

1.7 Intervalos de Credibilidad HPD (Highest Posterior Density)

Para cuantificar la incertidumbre, este trabajo implementa Intervalos de Máxima Densidad a Posteriori (HPD). A diferencia de los cuantiles simétricos que desperdician área en las asimetrías de la distribución Beta, el HPD garantiza que cualquier punto dentro del intervalo tiene mayor densidad que los puntos exteriores, lo cual se logra minimizando numéricamente la longitud total del intervalo.

Un intervalo de credibilidad simétrico del 95% se construye aislando estrictamente el 2.5% de la masa de probabilidad en cada cola de la distribución. Aunque este enfoque es estándar bajo el supuesto de normalidad asintótica, resulta teóricamente deficiente para distribuciones altamente asimétricas, como las distribuciones Beta que surgen al observar conteos de transición N_{ij} muy desbalanceados o nulos. En casos de sesgo extremo, obligar un corte del 2.5% en la cola más densa puede generar una paradoja estadística inaceptable: el intervalo resultante podría excluir a la moda poblacional (el estimador MAP), dejando fuera la estimación más probable del modelo.

Para solucionar esta inconsistencia, se implementa el intervalo HPD. El HPD se define formalmente como la región del espacio paramétrico que acumula una probabilidad de $1 - \gamma$ sujeto a la restricción de que la densidad de probabilidad de cualquier punto dentro del intervalo es estrictamente mayor o igual que la de cualquier punto exterior.

Matemáticamente, para una distribución unimodal continua, el HPD equivale al intervalo de mínima longitud posible. Al optimizar numéricamente esta longitud, el HPD garantiza congruencia absoluta con la función de pérdida "Todo o Nada", asegurando que el estimador MAP esté siempre contenido en la región de estimación e incrementando la precisión analítica al no desperdiciar amplitud en las asimetrías de las colas.

1.8 Validación Frecuentista mediante Simulación

Para validar empíricamente la cobertura de los estimadores propuestos, se desarrolló un simulador en Python. Se generaron 10,000 experimentos con $M = 50$ trayectorias independientes.